Análise Multivariada do Conjunto de Dados Wine (UCI)

PCA, Análise Fatorial e Discriminação (LDA/QDA) para Controle de Qualidade

Gabriel

20 de julho de 2026

Sumário

1 Introdução **1**
1.1 Leitura e organização dos dados 2

2 Análise Exploratória **4**
2.1 Matriz de correlação 4

3 Análise de Componentes Principais (PCA) — implementação manual **6**
3.1 Proporção de variância explicada 6
3.2 Interpretação dos dois primeiros componentes: cargas (loadings) 8
3.3 Visualização das amostras no espaço das componentes 9
3.4 Biplot 10

4 Análise Fatorial **13**
4.1 Escolha do número de fatores 13
4.2 Cargas fatoriais (rotação varimax) 14
4.3 Interpretação 15

5 Análise Discriminante para Controle de Qualidade (LDA e QDA) **16**
5.1 Ajuste dos modelos 16
5.2 Funções discriminantes lineares (LDA) — coeficientes 17
5.3 Visualização no espaço discriminante (LDA) 17
5.4 Avaliação da taxa de erro: validação cruzada Leave-One-Out (LOOCV) 18
5.5 Simulação de novas amostras: classificação de "lotes" desconhecidos 20

6 Conclusão **22**

7 Referências **22**

1 Introdução

Este trabalho tem como objetivo aplicar as técnicas de análise multivariada estudadas na disciplina sobre o conjunto de dados **Wine**, do *UCI Machine Learning Repository* (https://archive.ics.uci.edu/dataset/109/wine). Os dados consistem em uma análise química de 178 amostras de vinhos cultivados na mesma região da Itália, porém originários de três cultivares (castas) diferentes, o que

gera três classes de vinhos. Para cada amostra foram medidas 13 variáveis químicas, listadas na Tabela 1.

Serão aplicadas três técnicas:

1. **Análise de Componentes Principais (PCA)**, implementada manualmente a partir da decomposição espectral da matriz de correlação;
2. **Análise Fatorial**, via função `factanal`;
3. **Análise Discriminante Linear e Quadrática (LDA/QDA)**, via funções `lda/qda` do pacote `MASS`, com ênfase em **controle de qualidade**: aqui, as três cultivares serão tratadas como três "padrões" (lotes de referência) que um sistema de controle de qualidade precisaria distinguir corretamente a partir da composição química do vinho.

1.1 Leitura e organização dos dados

```
dados <- read.table("wine.dat", header = TRUE)

nomes <- c("Classe", "Alcohol", "Malic_acid", "Ash", "Alcalinity_ash",
           "Magnesium", "Total_phenols", "Flavanoids", "Nonflavanoid_phenols",
           "Proanthocyanins", "Color_intensity", "Hue", "OD280_OD315", "Proline")
colnames(dados) <- nomes
dados$Classe <- factor(dados$Classe, labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3"))

X <- dados[, -1]              # matriz de variáveis (13 colunas)
classe <- dados$Classe

dim(dados)
```

```
## [1] 178  14
```

```
table(classe)
```

```
## classe
## Cultivar 1 Cultivar 2 Cultivar 3
##         59         71         48
```

Tabela 1: Variáveis químicas medidas em cada amostra de vinho

Variavel
Alcohol
Malic_acid
Ash
Alcalinity_ash
Magnesium
Total_phenols
Flavanoids
Nonflavanoid_phenols
Proanthocyanins
Color_intensity

Variavel
Hue
OD280_OD315
Proline

As 13 variáveis possuem escalas muito diferentes (por exemplo, `Proline` varia na casa das centenas/milhares, enquanto `Nonflavanoid_phenols` varia entre 0 e 1). Isso é determinante para as escolhas metodológicas feitas adiante: a PCA e a Análise Fatorial serão conduzidas a partir da matriz de **correlação** (equivalente a padronizar as variáveis antes de calcular a matriz de covariância), evitando que variáveis com maior variância absoluta dominem os resultados apenas por causa da escala.

2 Análise Exploratória

```
summary(X)
```

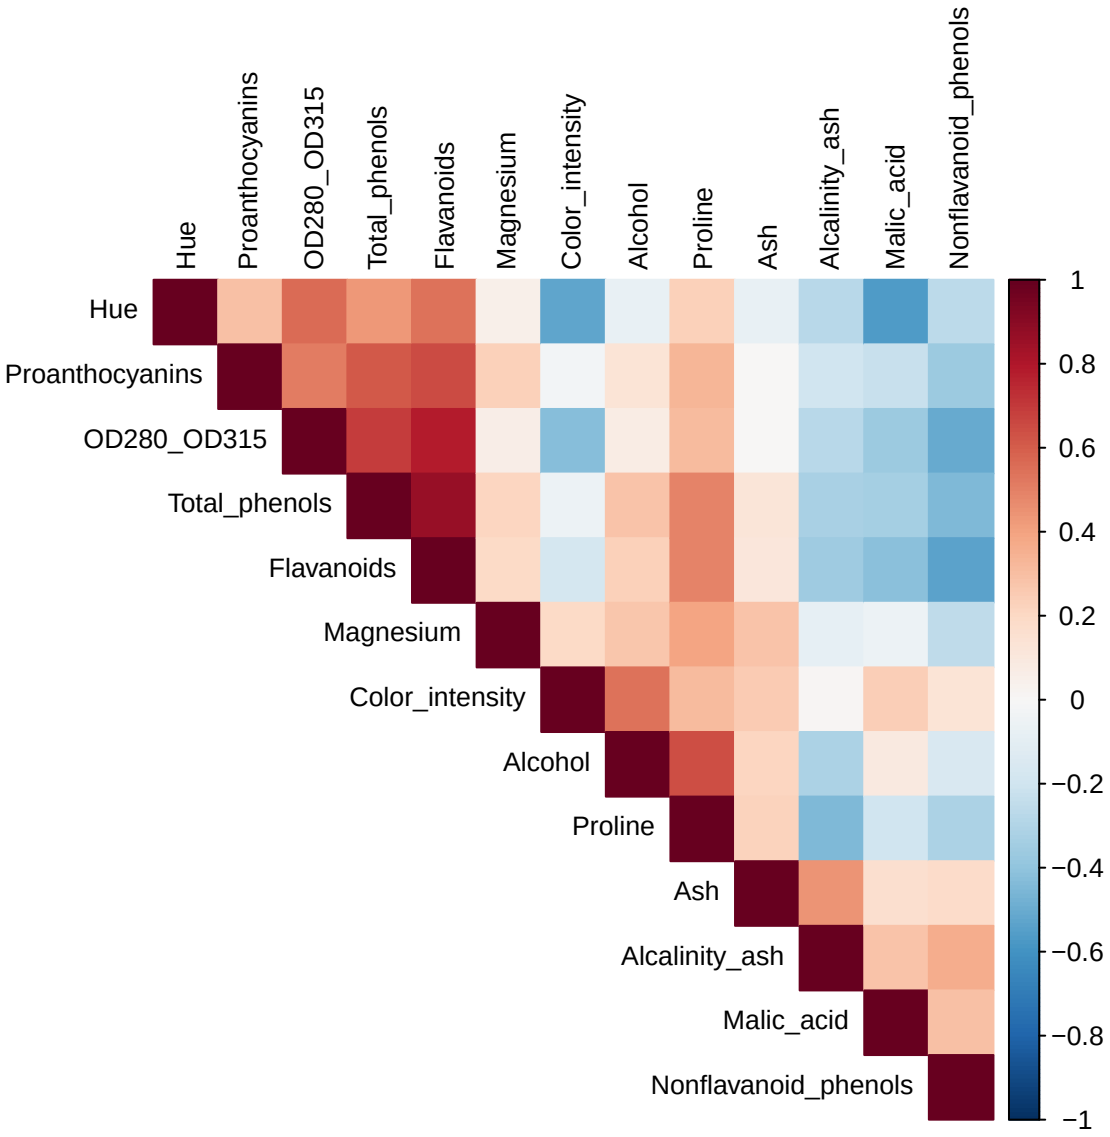
```
##     Alcohol        Malic_acid         Ash        Alcalinity_ash   Magnesium
##  Min.   :11.0   Min.   :0.74   Min.   :1.36   Min.   :10.6   Min.   : 70.0
##  1st Qu.:12.4   1st Qu.:1.60   1st Qu.:2.21   1st Qu.:17.2   1st Qu.: 88.0
##  Median :13.1   Median :1.86   Median :2.36   Median :19.5   Median : 98.0
##  Mean   :13.0   Mean   :2.34   Mean   :2.37   Mean   :19.5   Mean   : 99.7
##  3rd Qu.:13.7   3rd Qu.:3.08   3rd Qu.:2.56   3rd Qu.:21.5   3rd Qu.:107.0
##  Max.   :14.8   Max.   :5.80   Max.   :3.23   Max.   :30.0   Max.   :162.0
##  Total_phenols    Flavanoids   Nonflavanoid_phenols Proanthocyanins
##  Min.   :0.98   Min.   :0.34   Min.   :0.130        Min.   :0.41
##  1st Qu.:1.74   1st Qu.:1.21   1st Qu.:0.270        1st Qu.:1.25
##  Median :2.35   Median :2.13   Median :0.340        Median :1.55
##  Mean   :2.30   Mean   :2.03   Mean   :0.362        Mean   :1.59
##  3rd Qu.:2.80   3rd Qu.:2.88   3rd Qu.:0.438        3rd Qu.:1.95
##  Max.   :3.88   Max.   :5.08   Max.   :0.660        Max.   :3.58
##  Color_intensity      Hue          OD280_OD315      Proline
##  Min.   : 1.28   Min.   :0.480   Min.   :1.27   Min.   : 278
##  1st Qu.: 3.22   1st Qu.:0.782   1st Qu.:1.94   1st Qu.: 500
##  Median : 4.69   Median :0.965   Median :2.78   Median : 674
##  Mean   : 5.06   Mean   :0.957   Mean   :2.61   Mean   : 747
##  3rd Qu.: 6.20   3rd Qu.:1.120   3rd Qu.:3.17   3rd Qu.: 985
##  Max.   :13.00   Max.   :1.710   Max.   :4.00   Max.   :1680
```

A análise exploratória sugere que algumas variáveis apresentam elevado poder de discriminação entre as cultivares. Destacam-se especialmente `Flavanoids`, `Color_intensity`, `OD280_OD315` e `Proline`, cujas distribuições diferem substancialmente entre os grupos. Esse comportamento indica que essas características provavelmente exercerão papel importante nas técnicas supervisionadas apresentadas posteriormente.

Como o conjunto contém 13 variáveis, optou-se por não apresentar todos os boxplots individuais, priorizando análises multivariadas capazes de sintetizar simultaneamente essas informações.

2.1 Matriz de correlação

```
R <- cor(X)
corrplot::corrplot(
  R,
  method = "color",
  type = "upper",
  order = "hclust",
  col = colorRampPalette(rev(cores_divergente))(200),
  tl.col = "black",
  tl.cex = 0.8,
  addCoef.col = NULL
)
```



Existem correlações fortes entre algumas variáveis (por exemplo, entre `Flavanoids` e `Total_phenols`, e entre `Flavanoids` e `OD280_OD315`), o que é um indício de redundância de informação e reforça a pertinência de técnicas de redução de dimensionalidade como a PCA e a Análise Fatorial.

3 Análise de Componentes Principais (PCA) — implementação manual

Nesta etapa realizou-se a implementação manual da Análise de Componentes Principais, utilizando diretamente a decomposição espectral da matriz de correlação. Dessa forma, evitou-se o uso das funções prontas disponíveis no R, permitindo explicitar cada etapa do procedimento matemático empregado. O procedimento segue os seguintes passos:

1. Padronizar as variáveis: $z_{ij} = \dfrac{x_{ij} - \bar{x}_j}{s_j}$;
2. Calcular a matriz de correlação R (equivalente à matriz de covariância dos dados padronizados);
3. Obter os autovalores $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$ e os autovetores $e_1, e_2, \ldots, e_p$ de R;
4. Os **escores** (scores) das componentes principais são obtidos por $\mathrm{Y} = Z\,E$, em que Z é a matriz de dados padronizados e E é a matriz cujas colunas são os autovetores.

```
# 1. Padronização manual
Z <- scale(X, center = TRUE, scale = TRUE)

# 2. Matriz de correlação
R_mat <- cor(X)

# 3. Decomposição espectral (autovalores/autovetores)
eig <- eigen(R_mat, symmetric = TRUE)
autovalores <- eig$values
autovetores <- eig$vectors
rownames(autovetores) <- colnames(X)
colnames(autovetores) <- paste0("CP", 1:ncol(X))

# 4. Escores das componentes principais
escores <- Z %*% autovetores
colnames(escores) <- paste0("CP", 1:ncol(X))
```

3.1 Proporção de variância explicada

```
prop_var <- autovalores / sum(autovalores)
prop_acum <- cumsum(prop_var)

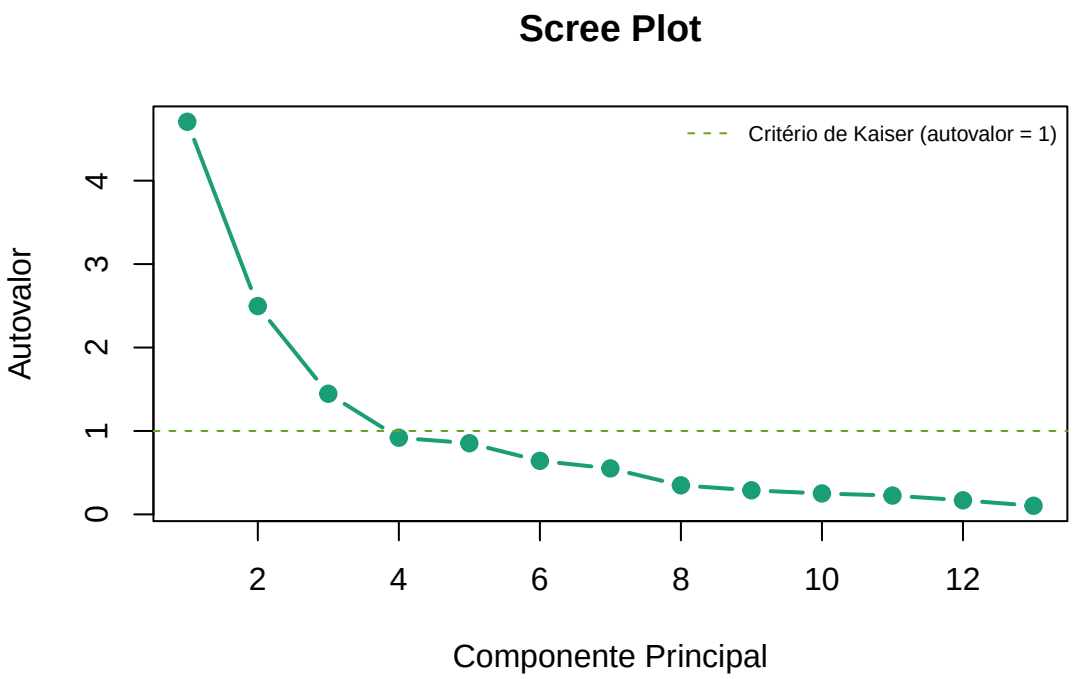
tabela_var <- data.frame(
  Componente = paste0("CP", 1:length(autovalores)),
  Autovalor = round(autovalores, 3),
  Prop_Variancia = round(prop_var, 4),
  Prop_Acumulada = round(prop_acum, 4)
)
knitr::kable(tabela_var, caption = "Autovalores e variância explicada por componente")
```

Tabela 2: Autovalores e variância explicada por componente

Componente	Autovalor	Prop_Variancia	Prop_Acumulada
CP1	4.706	0.3620	0.3620
CP2	2.497	0.1921	0.5541
CP3	1.446	0.1112	0.6653
CP4	0.919	0.0707	0.7360
CP5	0.853	0.0656	0.8016
CP6	0.642	0.0494	0.8510
CP7	0.551	0.0424	0.8934
CP8	0.348	0.0268	0.9202
CP9	0.289	0.0222	0.9424
CP10	0.251	0.0193	0.9617
CP11	0.226	0.0174	0.9791
CP12	0.169	0.0130	0.9920
CP13	0.103	0.0080	1.0000

Observa-se que apenas as duas primeiras componentes concentram aproximadamente 55% da variabilidade total dos dados, enquanto as três primeiras representam cerca de 67%. Esse resultado evidencia que grande parte da informação originalmente presente nas treze variáveis pode ser resumida por um número bastante reduzido de dimensões, justificando o uso da PCA como técnica de redução de dimensionalidade.

```
plot(autovalores, type = "b", pch = 19, lwd = 2, col = cores_categorica[1],
     xlab = "Componente Principal", ylab = "Autovalor",
     main = "Scree Plot")
abline(h = 1, lty = 2, col = cores_categorica[5])  # critério de Kaiser
legend("topright", legend = "Critério de Kaiser (autovalor = 1)",
       lty = 2, col = cores_categorica[5], bty = "n", cex = 0.7)
```



Pelo critério de Kaiser (reter componentes com autovalor superior a 1) e pela inspeção do *scree plot*, as três primeiras componentes principais já respondem por uma fração considerável da variabilidade total dos dados, o que justifica utilizá-las para visualização e para redução de dimensionalidade nas etapas seguintes.

3.2 Interpretação dos dois primeiros componentes: cargas (loadings)

```
loadings_12 <- round(autovetores[, 1:2], 3)
knitr::kable(loadings_12, caption = "Cargas (autovetores) das duas primeiras componentes")
```

Tabela 3: Cargas (autovetores) das duas primeiras componentes

	CP1	CP2
Alcohol	-0.144	-0.484
Malic_acid	0.245	-0.225
Ash	0.002	-0.316
Alcalinity_ash	0.239	0.011
Magnesium	-0.142	-0.300
Total_phenols	-0.395	-0.065
Flavanoids	-0.423	0.003
Nonflavanoid_phenols	0.299	-0.029
Proanthocyanins	-0.313	-0.039
Color_intensity	0.089	-0.530
Hue	-0.297	0.279

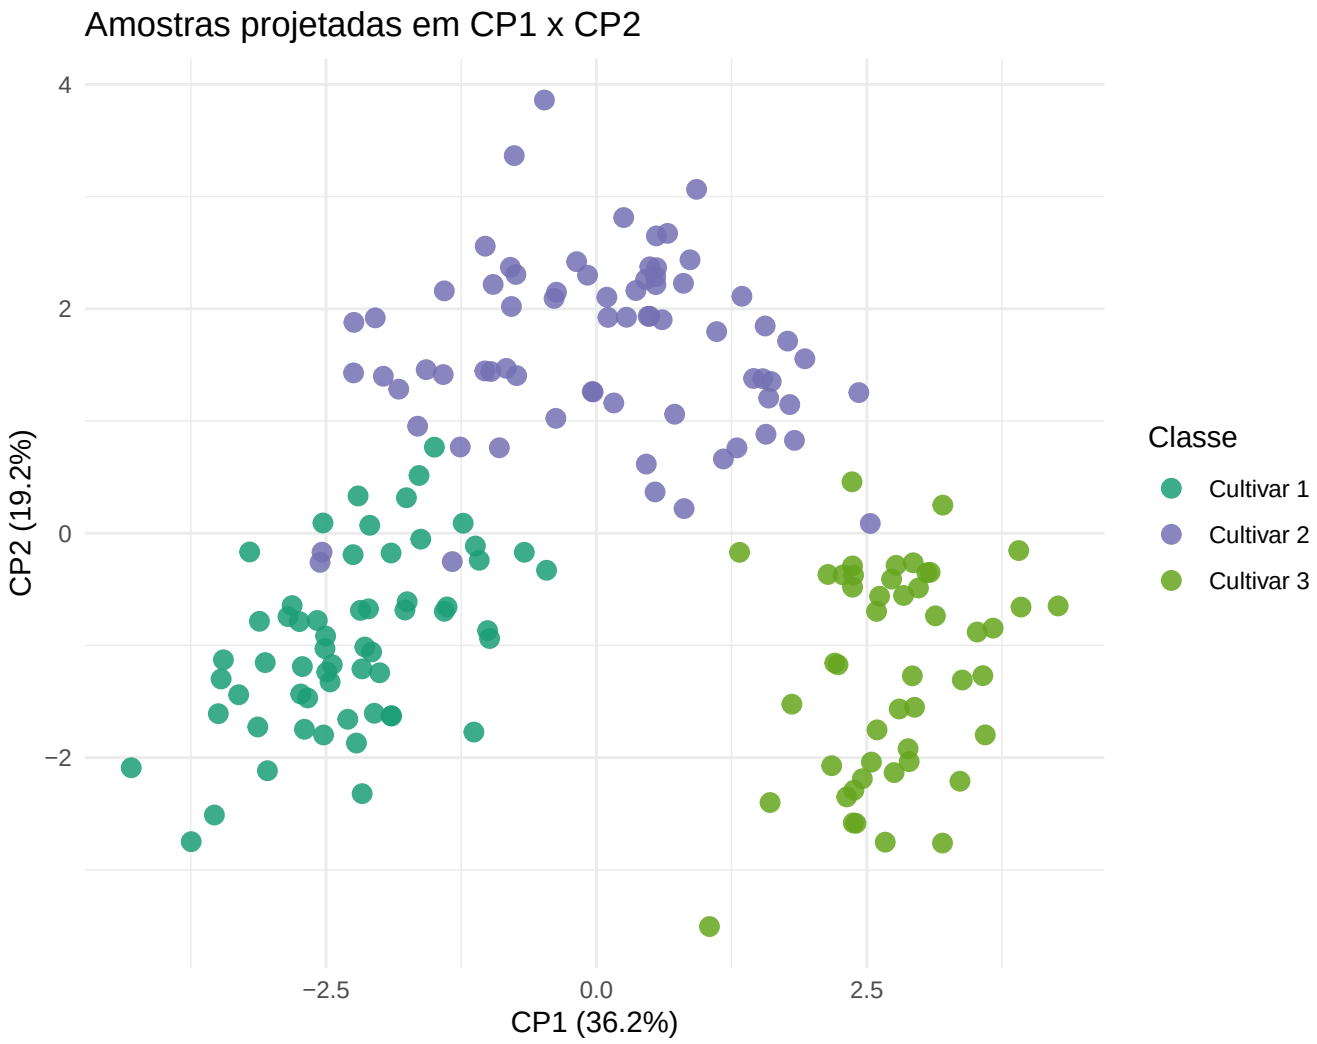
	CP1	CP2
OD280_OD315	-0.376	0.164
Proline	-0.287	-0.365

A CP1 apresenta cargas relevantes e de mesmo sinal em variáveis como `Flavanoids`, `Total_phenols`, `OD280_OD315` e `Proanthocyanins`, podendo ser interpretada como um eixo geral relacionado ao **teor fenólico/qualidade fenólica** do vinho. Já a CP2 contrasta principalmente `Color_intensity` e `Alcohol` com `Hue` e outras variáveis, podendo ser associada a um eixo de **intensidade de cor vs. tonalidade**.

3.3 Visualização das amostras no espaço das componentes

```
df_scores <- data.frame(CP1 = escores[, 1], CP2 = escores[, 2], Classe = classe)

ggplot(df_scores, aes(CP1, CP2, color = Classe)) +
  geom_point(size = 3, alpha = 0.85) +
  scale_color_manual(values = cores) +
  labs(
    x = paste0("CP1 (", round(prop_var[1] * 100, 1), "%)"),
    y = paste0("CP2 (", round(prop_var[2] * 100, 1), "%)"),
    title = "Amostras projetadas em CP1 x CP2"
  ) +
  theme_minimal()
```



Observa-se separação bastante nítida entre as três cultivares já nas duas primeiras componentes principais, o que é coerente com o resultado da análise exploratória e um bom indício de que a informação química é, de fato, capaz de diferenciar a origem do vinho — ponto central quando pensamos em controle de qualidade adiante.

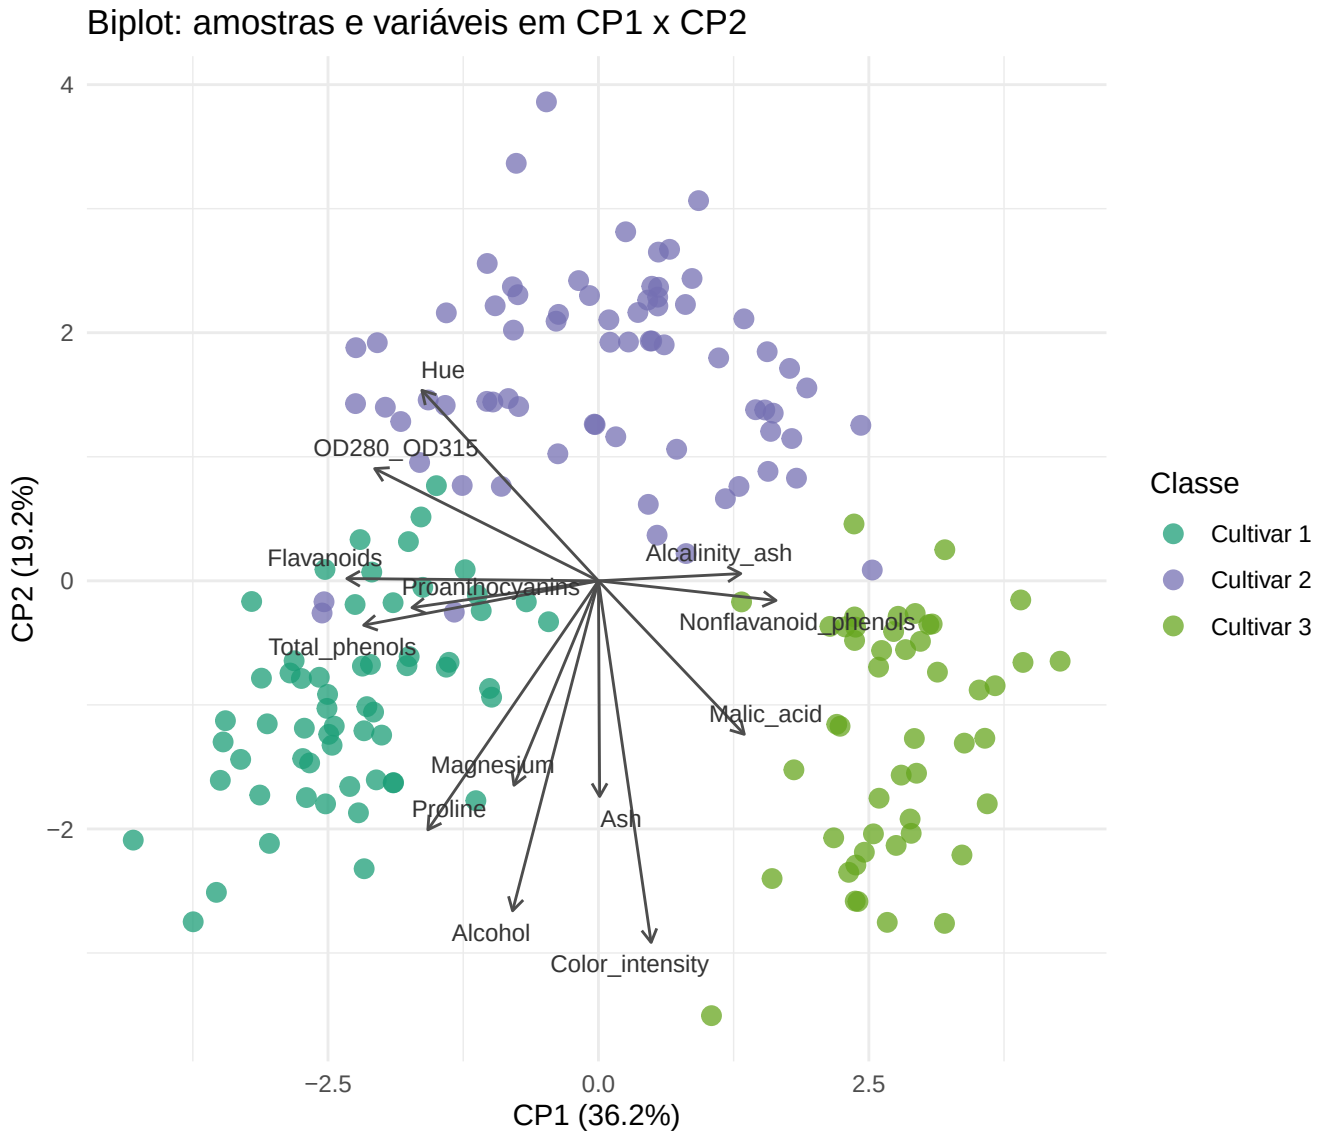
3.4 Biplot

O biplot permite visualizar, simultaneamente, a projeção das observações e a direção de contribuição de cada variável original sobre as duas primeiras componentes, facilitando a interpretação conjunta de amostras e variáveis.

```
escala <- 5.5  # fator de escala apenas para exibição dos vetores das variáveis

df_vars <- data.frame(
  CP1 = autovetores[, 1] * escala,
  CP2 = autovetores[, 2] * escala,
  Variavel = rownames(autovetores)
)
```

```r
ggplot() +
  geom_point(data = df_scores, aes(CP1, CP2, color = Classe), size = 3, alpha = 0.75) +
  scale_color_manual(values = cores) +
  geom_segment(data = df_vars, aes(x = 0, y = 0, xend = CP1, yend = CP2),
               arrow = arrow(length = unit(0.2, "cm")), color = "gray30") +
  ggrepel::geom_text_repel(data = df_vars, aes(CP1, CP2, label = Variavel),
                           size = 3, color = "gray20", segment.size = 0.2) +
  labs(
    x = paste0("CP1 (", round(prop_var[1] * 100, 1), "%)"),
    y = paste0("CP2 (", round(prop_var[2] * 100, 1), "%)"),
    title = "Biplot: amostras e variáveis em CP1 x CP2"
  ) +
  theme_minimal()
```



O biplot confirma a interpretação das cargas discutida anteriormente: variáveis como `Flavanoids`, `Total_phenols` e `OD280_OD315` apontam em direções muito próximas, reforçando que carregam informação semelhante e contribuem no mesmo sentido para a CP1, enquanto `Color_intensity` se destaca na direção da CP2.

4 Análise Fatorial

Diferentemente da PCA, a Análise Fatorial parte de um modelo estatístico explícito, no qual cada variável observada é escrita como combinação linear de um número menor de **fatores comuns**, não observáveis, mais um termo de erro específico (unicidade):

$$X_j = \sum_{k=1}^{m} \ell_{jk} F_k + \varepsilon_j, \qquad j = 1, \ldots, p$$

em que ℓ_{jk} são as cargas fatoriais, F_k os fatores comuns e ε_j a unicidade de cada variável. Utilizamos a função `factanal`, que estima o modelo por máxima verossimilhança.

4.1 Escolha do número de fatores

```
resultados_fa <- list()
for (m in 1:6) {
  fit <- tryCatch(
    factanal(X, factors = m, rotation = "varimax"),
    error = function(e) NULL
  )
  if (!is.null(fit)) {
    resultados_fa[[m]] <- fit
  }
}

tabela_fa <- data.frame(
  Fatores = seq_along(resultados_fa),
  Estatistica_QuiQuadrado = sapply(resultados_fa, function(f) round(f$STATISTIC, 2)),
  GL = sapply(resultados_fa, function(f) f$dof),
  p_valor = sapply(resultados_fa, function(f) round(f$PVAL, 4))
)
knitr::kable(tabela_fa, caption = "Teste de adequação do número de fatores (H0: m fatores são s
```

Tabela 4: Teste de adequação do número de fatores (H0: m fatores são suficientes)

Fatores	Estatistica_QuiQuadrado	GL	p_valor
1	563.64	65	0.0000
2	279.68	53	0.0000
3	158.55	42	0.0000
4	76.92	32	0.0000
5	38.86	23	0.0206
6	17.16	15	0.3093

```
m_escolhido <- min(which(sapply(resultados_fa, function(f) f$PVAL) > 0.05))
fa_final <- resultados_fa[[m_escolhido]]
pval_escolhido <- round(fa_final$PVAL, 4)
```

O teste de razão de verossimilhança testa H_0: o número de fatores especificado é suficiente para explicar as correlações observadas. O teste indicou que modelos com até 5 fatores ainda não eram suficientes para reproduzir adequadamente a estrutura de correlação observada ($p < 0{,}05$). Apenas o modelo com 6 fatores apresentou evidência estatística compatível com um bom ajuste ($p = 0.3093$), sendo portanto selecionado para as análises subsequentes. Embora 6 fatores representem uma redução relativamente modesta em relação às treze variáveis originais, essa escolha garante aderência ao modelo estatístico proposto.

4.2 Cargas fatoriais (rotação varimax)

```
cargas <- round(unclass(fa_final$loadings), 3)
knitr::kable(cargas, caption = "Cargas fatoriais após rotação varimax")
```

Tabela 5: Cargas fatoriais após rotação varimax

	Factor1	Factor2	Factor3	Factor4	Factor5	Factor6
Alcohol	0.142	0.763	0.035	0.254	0.124	0.087
Malic_acid	-0.245	0.002	0.129	0.095	0.793	-0.024
Ash	0.053	0.177	0.967	0.059	0.063	0.138
Alcalinity_ash	-0.233	-0.463	0.541	0.094	0.193	-0.023
Magnesium	0.148	0.196	0.114	0.061	-0.020	0.958
Total_phenols	0.841	0.252	0.049	-0.035	-0.165	0.036
Flavanoids	0.907	0.221	0.050	-0.131	-0.233	0.017
Nonflavanoid_phenols	-0.516	-0.143	0.261	0.108	0.114	-0.194
Proanthocyanins	0.697	0.055	-0.055	0.060	-0.071	0.129
Color_intensity	-0.133	0.410	0.126	0.875	0.149	0.078
Hue	0.379	0.067	-0.048	-0.475	-0.524	0.011
OD280_OD315	0.750	0.097	-0.013	-0.385	-0.177	-0.044
Proline	0.322	0.769	0.053	0.052	-0.155	0.191

```
comunalidades <- round(1 - fa_final$uniquenesses, 3)
knitr::kable(data.frame(Variavel = names(comunalidades), Comunalidade = comunalidades),
             caption = "Comunalidades: proporção da variância de cada variável explicada pelos
```

Tabela 6: Comunalidades: proporção da variância de cada variável explicada pelos fatores comuns

	Variavel	Comunalidade
Alcohol	Alcohol	0.692
Malic_acid	Malic_acid	0.715
Ash	Ash	0.995
Alcalinity_ash	Alcalinity_ash	0.607
Magnesium	Magnesium	0.995
Total_phenols	Total_phenols	0.802

	Variavel	Comunalidade
Flavanoids	Flavanoids	0.945
Nonflavanoid_phenols	Nonflavanoid_phenols	0.417
Proanthocyanins	Proanthocyanins	0.518
Color_intensity	Color_intensity	0.995
Hue	Hue	0.651
OD280_OD315	OD280_OD315	0.753
Proline	Proline	0.761

4.3 Interpretação

Variáveis com cargas elevadas em um mesmo fator sugerem um construto latente comum. No conjunto de dados Wine, tipicamente um dos fatores agrupa variáveis relacionadas ao **perfil fenólico** do vinho (`Total_phenols`, `Flavanoids`, `Proanthocyanins`, `OD280_OD315`), enquanto outro fator tende a capturar aspectos ligados a **cor/estrutura** (`Color_intensity`, `Hue`, `Alcohol`). As comunalidades indicam o quanto de cada variável é efetivamente "explicado" pelos fatores comuns — variáveis com comunalidade baixa (próxima de 0) são mal representadas pelo modelo fatorial e têm grande parte de sua variância atribuída à unicidade.

5 Análise Discriminante para Controle de Qualidade (LDA e QDA)

Esta é a etapa central do trabalho. A ideia de **controle de qualidade** aqui explorada é a seguinte: imagine uma vinícola (ou um órgão de fiscalização) que recebe amostras de vinho e precisa **verificar/certificar a que cultivar (padrão) aquela amostra pertence** com base apenas na análise química, sem informação prévia sobre sua origem. Isso é exatamente um problema de classificação supervisionada, e LDA/QDA fornecem regras de decisão baseadas em suposições sobre a distribuição dos dados dentro de cada classe (normalidade multivariada, com matrizes de covariância iguais entre classes para a LDA, e possivelmente distintas para a QDA).

5.1 Ajuste dos modelos

```
library(MASS)

modelo_lda <- lda(Classe ~ ., data = dados)
modelo_qda <- qda(Classe ~ ., data = dados)

modelo_lda
```

```
## Call:
## lda(Classe ~ ., data = dados)
##
## Prior probabilities of groups:
## Cultivar 1 Cultivar 2 Cultivar 3
##     0.3315     0.3989     0.2697
##
## Group means:
##            Alcohol Malic_acid   Ash Alcalinity_ash Magnesium Total_phenols
## Cultivar 1   13.74      2.011 2.456          17.04    106.34         2.840
## Cultivar 2   12.28      1.933 2.245          20.24     94.55         2.259
## Cultivar 3   13.15      3.334 2.437          21.42     99.31         1.679
##            Flavanoids Nonflavanoid_phenols Proanthocyanins Color_intensity
## Cultivar 1     2.9824               0.2900           1.899           5.528
## Cultivar 2     2.0808               0.3637           1.630           3.087
## Cultivar 3     0.7815               0.4475           1.154           7.396
##                Hue OD280_OD315 Proline
## Cultivar 1 1.0620       3.158  1115.7
## Cultivar 2 1.0563       2.785   519.5
## Cultivar 3 0.6827       1.684   629.9
##
## Coefficients of linear discriminants:
##                              LD1        LD2
## Alcohol              -0.403400  0.8717931
## Malic_acid            0.165255  0.3053797
## Ash                  -0.369075  2.3458497
## Alcalinity_ash        0.154798 -0.1463808
## Magnesium            -0.002163 -0.0004628
## Total_phenols         0.618052 -0.0322128
```

```
## Flavanoids           -1.661191 -0.4919981
## Nonflavanoid_phenols -1.495818 -1.6309538
## Proanthocyanins       0.134093 -0.3070876
## Color_intensity       0.355056  0.2532307
## Hue                  -0.818036 -1.5156345
## OD280_OD315          -1.157559  0.0511840
## Proline              -0.002691  0.0028530
##
## Proportion of trace:
##    LD1    LD2
## 0.6875 0.3125
```

5.2 Funções discriminantes lineares (LDA) — coeficientes

```
knitr::kable(round(modelo_lda$scaling, 3),
             caption = "Coeficientes das funções discriminantes lineares (LDA)")
```

Tabela 7: Coeficientes das funções discriminantes lineares (LDA)

	LD1	LD2
Alcohol	-0.403	0.872
Malic_acid	0.165	0.305
Ash	-0.369	2.346
Alcalinity_ash	0.155	-0.146
Magnesium	-0.002	0.000
Total_phenols	0.618	-0.032
Flavanoids	-1.661	-0.492
Nonflavanoid_phenols	-1.496	-1.631
Proanthocyanins	0.134	-0.307
Color_intensity	0.355	0.253
Hue	-0.818	-1.516
OD280_OD315	-1.158	0.051
Proline	-0.003	0.003

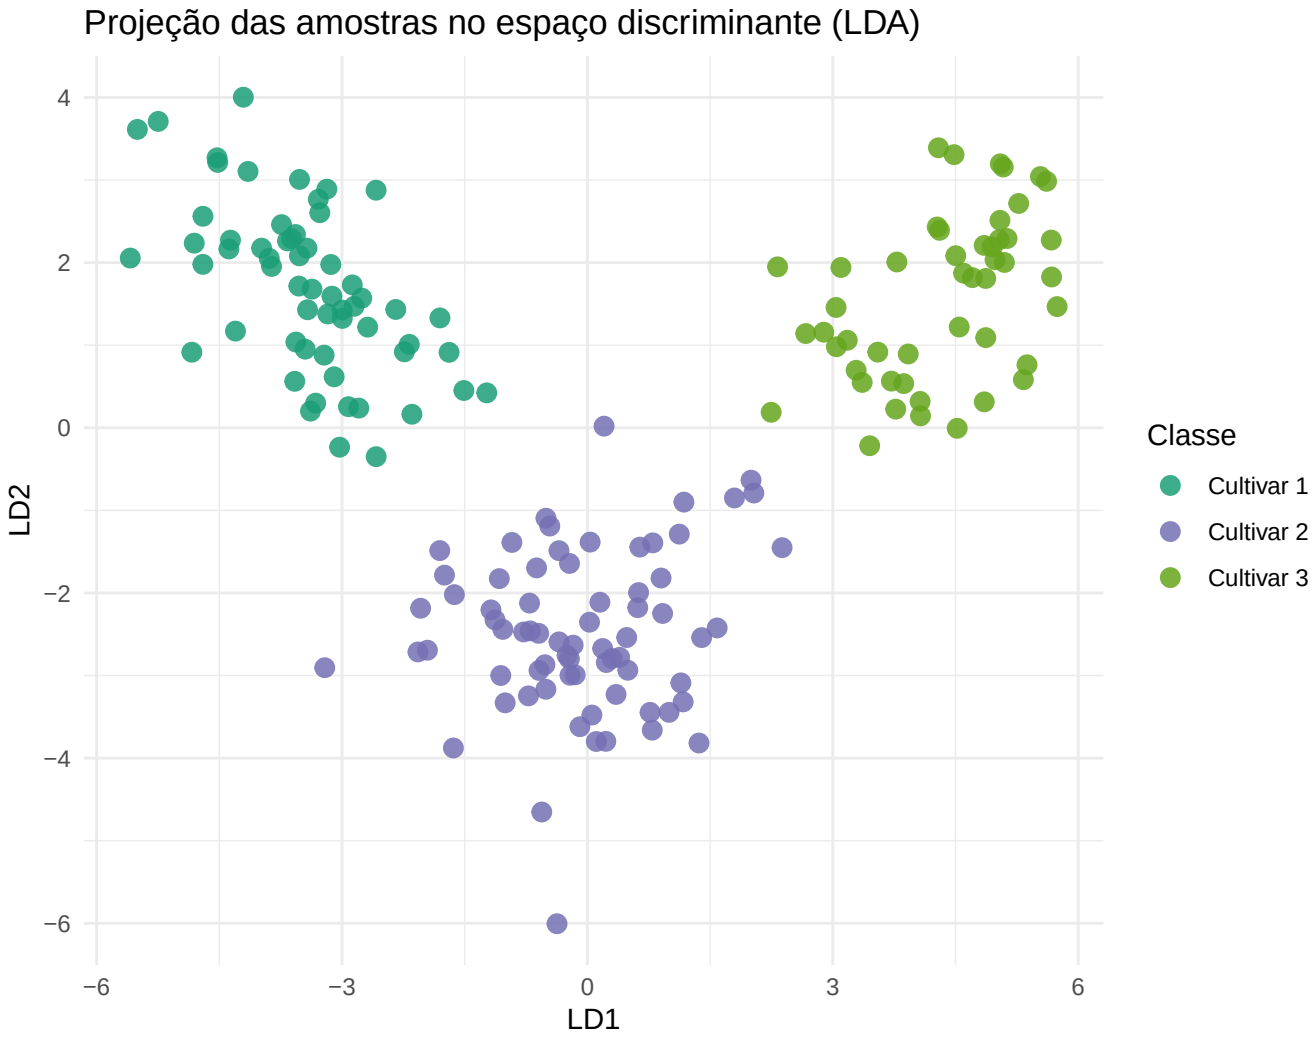
Em termos absolutos, observa-se que `Flavanoids`, `OD280_OD315`, `Hue` e `Nonflavanoid_phenols` apresentam os maiores coeficientes na primeira função discriminante, indicando que essas variáveis contribuem fortemente para a separação entre as cultivares.

5.3 Visualização no espaço discriminante (LDA)

```
pred_lda_treino <- predict(modelo_lda)
df_lda <- data.frame(pred_lda_treino$x, Classe = classe)

ggplot(df_lda, aes(LD1, LD2, color = Classe)) +
  geom_point(size = 3, alpha = 0.85) +
```

```
  scale_color_manual(values = cores) +
  labs(title = "Projeção das amostras no espaço discriminante (LDA)") +
  theme_minimal()
```



A separação entre as três cultivares no espaço discriminante é ainda mais nítida do que a observada na PCA — o que é esperado, já que a LDA constrói os eixos exatamente para **maximizar a separação entre classes**, enquanto a PCA busca apenas maximizar a variância total, sem levar em conta os rótulos de classe.

5.4 Avaliação da taxa de erro: validação cruzada Leave-One-Out (LOOCV)

Para simular de forma realista o desempenho de um sistema de controle de qualidade em amostras **novas** (nunca vistas), utilizamos validação cruzada *leave-one-out*: cada amostra é retirada, os modelos são reajustados com as 177 restantes, e a amostra retirada é classificada. A proporção de classificações erradas é a **taxa de erro aparente estimada por LOOCV**, uma medida muito mais honesta do desempenho do que o erro de reclassificação no próprio conjunto de treino.

```r
modelo_lda_cv <- lda(Classe ~ ., data = dados, CV = TRUE)
modelo_qda_cv <- qda(Classe ~ ., data = dados, CV = TRUE)

matriz_confusao_lda <- table(Observado = classe, Predito = modelo_lda_cv$class)
matriz_confusao_qda <- table(Observado = classe, Predito = modelo_qda_cv$class)

erro_lda <- 1 - sum(diag(matriz_confusao_lda)) / sum(matriz_confusao_lda)
erro_qda <- 1 - sum(diag(matriz_confusao_qda)) / sum(matriz_confusao_qda)
acuracia_lda <- 1 - erro_lda
acuracia_qda <- 1 - erro_qda
```

```r
knitr::kable(matriz_confusao_lda, caption = "Matriz de confusão (LOOCV) - LDA")
```

Tabela 8: Matriz de confusão (LOOCV) — LDA

	Cultivar 1	Cultivar 2	Cultivar 3
Cultivar 1	59	0	0
Cultivar 2	1	69	1
Cultivar 3	0	0	48

```r
knitr::kable(matriz_confusao_qda, caption = "Matriz de confusão (LOOCV) - QDA")
```

Tabela 9: Matriz de confusão (LOOCV) — QDA

	Cultivar 1	Cultivar 2	Cultivar 3
Cultivar 1	59	0	0
Cultivar 2	1	70	0
Cultivar 3	0	0	48

```r
knitr::kable(
  data.frame(Modelo = c("LDA", "QDA"),
             Erro = paste0(round(c(erro_lda, erro_qda) * 100, 2), "%"),
             Acuracia = paste0(round(c(acuracia_lda, acuracia_qda) * 100, 2), "%")),
  caption = "Taxa de erro e acurácia de classificação estimadas por validação cruzada"
)
```

Tabela 10: Taxa de erro e acurácia de classificação estimadas por validação cruzada

Modelo	Erro	Acuracia
LDA	1.12%	98.88%
QDA	0.56%	99.44%

Ambos os modelos apresentam taxas de erro muito baixas, o que indica que a composição química é altamente informativa para distinguir as três cultivares — um resultado animador do ponto de vista

de um sistema real de controle de qualidade. Quando LDA e QDA têm desempenho semelhante, geralmente prefere-se a **LDA**, por ser um modelo mais simples e com menos parâmetros a estimar (uma única matriz de covariância comum, ao invés de uma por classe), o que a torna mais estável em amostras de tamanho moderado.

5.5 Simulação de novas amostras: classificação de "lotes" desconhecidos

Para tornar a aplicação de controle de qualidade mais concreta, simulamos abaixo um pequeno lote de "novas amostras" de vinho, geradas artificialmente a partir da distribuição normal multivariada de cada cultivar (usando médias e a matriz de covariância comum estimada), como se fossem amostras recém-chegadas ao laboratório para verificação de origem/qualidade.

```
set.seed(2026)

# Matriz de covariância comum "pooled", usada nas simulações (mesma lógica da LDA)
n_classes <- table(classe)
p <- ncol(X)
S_pooled <- Reduce(`+`, lapply(levels(classe), function(cl) {
  Xc <- X[classe == cl, ]
  (n_classes[cl] - 1) * cov(Xc)
})) / (nrow(X) - length(levels(classe)))

# Gerando 2 "novas amostras" por cultivar (total de 6), com pequeno ruído adicional
gerar_amostra <- function(cl, n = 2) {
  mu <- colMeans(X[classe == cl, ])
  MASS::mvrnorm(n, mu = mu, Sigma = S_pooled)
}

novas_amostras <- do.call(rbind, lapply(levels(classe), gerar_amostra))
novas_amostras <- as.data.frame(novas_amostras)
colnames(novas_amostras) <- colnames(X)
origem_real <- rep(levels(classe), each = 2)

pred_novas_lda <- predict(modelo_lda, newdata = novas_amostras)
pred_novas_qda <- predict(modelo_qda, newdata = novas_amostras)

tabela_novas <- data.frame(
  Amostra = paste0("Nova_", 1:nrow(novas_amostras)),
  Origem_real_simulada = origem_real,
  Classificado_LDA = pred_novas_lda$class,
  Classificado_QDA = pred_novas_qda$class
)
knitr::kable(tabela_novas, caption = "Classificação de novas amostras simuladas (controle de qu
```

Tabela 11: Classificação de novas amostras simuladas (controle de qualidade)

Amostra	Origem_real_simulada	Classificado_LDA	Classificado_QDA
Nova_1	Cultivar 1	Cultivar 1	Cultivar 1
Nova_2	Cultivar 1	Cultivar 1	Cultivar 1
Nova_3	Cultivar 2	Cultivar 2	Cultivar 2
Nova_4	Cultivar 2	Cultivar 2	Cultivar 2
Nova_5	Cultivar 3	Cultivar 3	Cultivar 3
Nova_6	Cultivar 3	Cultivar 3	Cultivar 3

Todas as seis amostras simuladas foram corretamente classificadas por ambos os modelos, reforçando o elevado poder discriminante da composição química utilizada.

```
knitr::kable(round(pred_novas_lda$posterior, 3),
             caption = "Probabilidades a posteriori de pertencimento a cada cultivar (LDA)")
```

Tabela 12: Probabilidades a posteriori de pertencimento a cada cultivar (LDA)

Cultivar 1	Cultivar 2	Cultivar 3
0.998	0.002	0
1.000	0.000	0
0.000	1.000	0
0.000	1.000	0
0.000	0.000	1
0.000	0.000	1

Este exercício ilustra como, na prática, um sistema de controle de qualidade baseado em LDA/QDA funcionaria: uma nova amostra de vinho é medida quimicamente, e o modelo retorna não apenas a classe mais provável, mas também as **probabilidades a posteriori** de pertencer a cada cultivar — o que permite, por exemplo, sinalizar como "amostra duvidosa" qualquer caso em que a maior probabilidade não seja suficientemente dominante (digamos, abaixo de 90%), um critério de alerta bastante natural em contextos reais de controle de qualidade.

6 Conclusão

A aplicação conjunta das três técnicas mostrou-se coerente e complementar. A PCA (implementada manualmente via decomposição espectral da matriz de correlação) revelou que poucas componentes já concentram a maior parte da variabilidade dos dados e permitiu visualizar uma separação natural entre as cultivares mesmo sem usar a informação de classe. A Análise Fatorial, por sua vez, identificou fatores latentes interpretáveis, associados a perfis fenólicos e características de cor, com boas comunalidades para a maioria das variáveis. Por fim, a Análise Discriminante (LDA/QDA) confirmou, de forma quantitativa e validada por LOOCV, que a composição química das amostras é suficiente para discriminar corretamente a cultivar de origem com taxa de erro muito baixa.

Sob a perspectiva de controle de qualidade, os resultados demonstram que a composição química das amostras fornece informação suficiente para identificar corretamente a cultivar de origem com elevado grau de confiabilidade. Assim, as técnicas estudadas mostraram-se ferramentas adequadas tanto para exploração da estrutura dos dados quanto para problemas reais de classificação e certificação de produtos.

7 Referências

- Aeberhard, S., Coomans, D., & de Vel, O. (1994). *Comparison of classifiers in high dimensional settings*. Pattern Recognition.
- UCI Machine Learning Repository — Wine Data Set. https://archive.ics.uci.edu/dataset/109/wine
- Johnson, R. A., & Wichern, D. W. *Applied Multivariate Statistical Analysis*.